

Relatório TP4: Análise Exploratória, PCA e Classificação K-NN no Dataset Iris

Gabriel Augusto Fabri Soltovski GRR20222546
Ricardo Quer GRR20224827

6 de outubro de 2026

Repositório Git: <https://github.com/GAFS-GAFS/Vis-oComputacional>

1 Introdução e Visão Geral do Dataset

O dataset *Iris* da UCI Machine Learning Repository é composto por 150 amostras de flores divididas igualmente em 3 classes (50 amostras cada, representando 33,33% por classe):

- *Iris setosa*
- *Iris versicolor*
- *Iris virginica*

Cada instância é caracterizada por 4 atributos contínuos mensurados em centímetros: comprimento da sépala, largura da sépala, comprimento da pétala e largura da pétala.

2 Estatística Descritiva

A Tabela 1 apresenta as métricas de média (μ), desvio padrão (σ) e moda para cada atributo no dataset geral e estratificado por espécie.

Tabela 1: Média, desvio padrão e moda dos atributos (em cm).

Atributo	Geral	Setosa	Versicolor	Virginica
Comp. Sépala	$5,84 \pm 0,83$ (M: 5,0)	$5,01 \pm 0,35$ (M: 5,0)	$5,94 \pm 0,52$ (M: 5,5)	$6,59 \pm 0,64$ (M: 6,3)
Larg. Sépala	$3,05 \pm 0,43$ (M: 3,0)	$3,42 \pm 0,38$ (M: 3,4)	$2,77 \pm 0,31$ (M: 3,0)	$2,97 \pm 0,32$ (M: 3,0)
Comp. Pétala	$3,76 \pm 1,76$ (M: 1,5)	$1,46 \pm 0,17$ (M: 1,5)	$4,26 \pm 0,47$ (M: 4,5)	$5,55 \pm 0,55$ (M: 5,1)
Larg. Pétala	$1,20 \pm 0,76$ (M: 0,2)	$0,24 \pm 0,11$ (M: 0,2)	$1,33 \pm 0,20$ (M: 1,3)	$2,03 \pm 0,27$ (M: 1,8)

Observações principais:

1. A *Iris setosa* distingue-se fortemente pelas pétalas curtas e estreitas ($\mu = 1,46$ cm e $\mu = 0,24$ cm), além de ter a maior largura média de sépalas (3,42 cm).
2. A *Iris virginica* apresenta as maiores dimensões gerais de pétalas ($\mu = 5,55$ cm e $\mu = 2,03$ cm).

3 Análise de Relações e Distribuição Multidimensional

3.1 Relações Sépala e Pétala

A correlação entre comprimento e largura varia expressivamente entre atributos e categorias:

- **Sépala (Figura 1):** Correlação positiva forte para *Setosa* ($r = 0,75$), e moderada para *Versicolor* ($r = 0,53$) e *Virginica* ($r = 0,46$).
- **Pétala (Figura 2):** Forte correlação linear para *Versicolor* ($r = 0,79$), moderada para *Virginica* ($r = 0,32$) e *Setosa* ($r = 0,31$). As pétalas proporcionam uma separação visual quase perfeita entre as 3 classes.




Figura 1: Dispersão entre comprimento e largura da sépala por espécie.

3.2 Distribuição nas 4 Dimensões

A Figura 3 sintetiza as distribuições por meio de boxplots. Observa-se que o comprimento e a largura da pétala possuem baixa sobreposição interquartil entre espécies, sendo as variáveis de maior poder discriminante.

4 Análise de Componentes Principais (PCA)

A técnica de PCA foi aplicada sobre os 4 atributos padronizados para projetar os dados em 2 dimensões.

- **PC1 (Primeiro Componente):** retém **72,77%** da variância total.
- **PC2 (Segundo Componente):** retém **23,03%** da variância total.




Figura 2: Dispersão entre comprimento e largura da pétala por espécie.




Figura 3: Distribuição dos quatro atributos por categoria (Boxplots).

- **Variância Explicada Acumulada: 95,80%.**




Figura 4: Projecção bidimensional via PCA (PC1 vs PC2).

Como evidenciado na Figura 4, a projecção 2D preserva quase a totalidade da informação do espaço 4D original. A classe *Setosa* é isolada de forma linearmente separável, enquanto *Versicolor* e *Virginica* formam agrupamentos bem distintos com leve proximidade na fronteira de decisão.

5 Classificação Supervisionada com K-NN

Os dados foram divididos em ****80% para treino (120 amostras)**** e ****20% para teste (30 amostras, 10 de cada classe)****, utilizando amostragem estratificada.




Figura 5: Acurácia no conjunto de teste em função do número de vizinhos (k).

Avaliando $k \in [1, 15]$ (Figura 5), o classificador atinge desempenho excelente. Para $k = 3$, obteve-se:




Figura 6: Matriz de confusão para o classificador K-NN ($k = 3$).

- **Acurácia Global: 100,0%** (30 acertos em 30 predições).
- **Precisão, Revocação e F1-Score: 1,00** para todas as três classes (Figura 6).

6 Conclusão

O estudo demonstrou a eficácia dos métodos estatísticos e de aprendizado de máquina sobre o dataset Iris:

1. As dimensões das pétalas são os atributos mais informativos e discriminantes entre as espécies.
2. O PCA reduziu a dimensionalidade de 4D para 2D mantendo 95,8% da variância, confirmando a separabilidade geométrica das classes.
3. O classificador K-NN obteve separação perfeita das classes no conjunto de teste com 80% de treinamento, ratificando a consistência dos agrupamentos naturais dos dados.