

Relatório TP5: Estudo, Depuração e Experimentos com MLP from Scratch no Dataset Iris

Gabriel Augusto Fabri Soltovski GRR20222546

Ricardo Quer GRR20224827

6 de outubro de 2026

Repositório Git: <https://github.com/GAFS-GAFS/Vis-oComputacional>

Notebook Original (Colab): [Link Google Colab](#)

1 Introdução e Objetivo

O objetivo deste trabalho prático é analisar, depurar e aprimorar a implementação de uma rede neural *Multi-Layer Perceptron* (MLP) desenvolvida do zero (*from scratch*) em Python/NumPy para classificação das três espécies do dataset *Iris* (Setosa, Versicolor e Virginica).

A partir do código disponibilizado, realizou-se o diagnóstico de inconsistências matemáticas e algorítmicas, experimentos de convergência do erro quadrático médio (MSE), investigação de sobreajuste (*overfitting*) e proposição de uma arquitetura otimizada para correta separação das classes.

2 Diagnóstico e Depuração do Código Original

Durante a análise minuciosa da implementação fornecida no notebook, identificaram-se quatro problemas fundamentais:

1. **Bug Crítico na Inferência (predict):** No método de predição, a ativação da camada oculta não era aplicada (`forward = np.matmul(X, W_hidden) + b_hidden`). O sinal era repassado linearmente à camada de saída, anulando a não-linearidade sigmoide aprendida durante o treinamento.
2. **Ausência de Normalização dos Dados:** Os atributos de Iris possuem valores de até 7,9. Entradas com essa magnitude saturam a função sigmoide $\sigma(z)$, fazendo com que a derivada $\sigma'(z) = \sigma(z)(1 - \sigma(z))$ se aproxime de zero (*vanishing gradient*). Isso provocava lentidão extrema e incapacidade de separar classes próximas sem milhares de épocas.

3. **Sequência Incorreta de Atualização no Backpropagation:** Os pesos da camada de saída (`WEIGHT_output`) eram atualizados antes do cálculo do gradiente da camada oculta (`delta_hidden`), retropropagando o erro com pesos já modificados.
4. **Cálculo Irregular de Erro:** Acúmulo distorcido do MSE com um fator arbitrário de 0,05.

A Tabela 1 resume o impacto das correções na acurácia do conjunto de teste (20% dos dados, 30 amostras):

Tabela 1: Comparativo de Acurácia após Etapas de Depuração.

Versão do Modelo	Acurácia no Teste (%)
1. Código Original (com bug no <code>predict</code> e dados brutos)	66,67%
2. Código com <code>predict</code> Corrigido (dados brutos)	96,67%
3. Modelo Otimizado (Normalizado + Backprop Sincronizado)	100,00%

3 Análise de Convergência e Erros

A Figura 1 compara a evolução do MSE ao longo do treinamento. O modelo original com dados brutos necessita de mais de 1000 épocas e taxa de aprendizado ínfima ($\eta = 0,005$) devido à saturação sigmoideal. Por outro lado, com os dados normalizados via `StandardScaler` e taxa $\eta = 0,08$, o modelo otimizado converge estavelmente para erro residual mínimo em menos de 300 épocas.




Figura 1: Curvas de convergência do MSE: Modelo Original vs. Modelo Otimizado.

4 Análise de Overfitting e Early Stopping

Para avaliar o risco de sobreajuste (*overfitting*), treinou-se o modelo por 1200 épocas monitorando simultaneamente a perda no conjunto de treinamento e no conjunto de teste (Figura 2).




Figura 2: Perda no Treino vs. Perda no Teste evidenciando o ponto ótimo de parada.

Observa-se que, enquanto o erro de treino decresce continuamente em direção a zero, o erro de teste atinge seu ponto mínimo em torno da época 350 a 450 e tende a se estabilizar. Esse comportamento confirma a importância do critério de *Early Stopping* para evitar a memorização excessiva das amostras de treino.

5 Resultados da Classificação das Três Classes

Com a entrada normalizada e 8 neurônios na camada oculta, a rede neural obteve separação perfeita das três espécies no conjunto de teste. A Figura 3 exibe a matriz de confusão e a Figura 4 ilustra as fronteiras de decisão não-lineares aprendidas no espaço bidimensional das pétalas.




Figura 3: Matriz de confusão no conjunto de teste (Acurácia: 100,0%).

Métricas Finais: Precisão, revocação e F1-Score iguais a 1,00 para todas as classes (*Setosa*, *Versicolor* e *Virginica*).




Figura 4: Fronteiras de decisão da rede MLP no plano das pétalas.

6 Conclusão

O estudo da implementação do MLP *from scratch* evidenciou que pequenos deslizes na fase de inferência (como a omissão da ativação no `predict`) e a ausência de pré-processamento comprometem gravemente o desempenho de redes neurais. A padronização dos atributos associada à correta sincronização do algoritmo de retropropagação permitiu atingir convergência rápida e acurácia de 100% na discriminação das três espécies da base Iris.